

AI+ICF设计问题：多种任务类型

- **代理模型 (回归问题)**
 - 给定设计参数，预测输出
- **辅助设计 (约束优化问题)**
 - 给定等式/不等式约束：预测设计空间可行域
- **定标率 (全局/局部相关性分析问题)**
 - 全局：点火能量 vs 内爆速度
 - 局部：速度 vs Atwood数...

多样的模型架构


- NN代理模型...
- 遗传算法优化；蒙卡/贝叶斯后验分析...
- 响应函数预测；局部线性回归 ($y = x_1^a x_2^b x_3^c$)...

在输入/输出维度间互相预测



自然语言处理：

- 词性标注
- 语句情感判断
- 句子逻辑关系标注
- 文本摘要、扩写
- 翻译、问答...
- N-gram/CNN
- RNN/LSTM
- RNN + attention
- ...



所有信息都蕴含在数据的高维分布中

$$\mathbf{x} = (\text{Tr}, \text{Tr}_{\text{foot}}, R, \Delta_{\text{DT}}, \dots) \quad \mathbf{y} = (\log Y, v_{\text{imp}}, \alpha_{\text{DT}}, \rho R, \dots)$$

- 原则上，只要学到了 data+label 空间的高维分布 $p(x_1 \dots x_n, y_1 \dots y_m) = \frac{1}{Z} e^{-\beta H(x_1 \dots x_n, y_1 \dots y_m)}$
 - $p(y|x)$ 就是从x预测y的代理模型
 - $p(x_2|y_1, x_1)$ 就是在给定约束下的逆向设计工具
 - $p(y_2|y_1)$ 就是不同性能指标间的定标率...


- 不同于经典的概率图模型(eg.RBM)，我们使用自回归生成模型来逼近这个高维联合分布
 - 现代生成模型：自回归(Autoregression) 扩散模型(Diffusion)
 - 只需要训练一个能从前文预测后文、也能从后文预测前文、也能从中间预测两头... 即，能以任意语序预测下一位分布的GPT；原则上就能回答上述所有问题。

- 我们关心设计量 $\mathbf{x}=(\text{Tr}, \text{Tr}_{\text{foot}}, R, \dots)$ 与模拟输出量 $\mathbf{y}=(\log Y, v_{\text{imp}}, \alpha_{\text{DT}}, \dots)$ 放在一起的联合分布
- 自回归的数学本质：任何复杂的高维分布都可以展开成条件分布的乘积：


$$p(x_1, x_2, x_3, \dots) = p(x_1) p(x_2|x_1) p(x_3|x_2) \dots$$

- 由于条件概率分解可以按任意次序进行, $p(x_1, x_2, x_3, \dots) = p(x_3) p(x_1|x_3) p(x_2|x_1) \dots$;
我们完全可以做一个有严格概率论含义的“乱序GPT”，来处理不同物理量间的关联：

GPT：条件前面的词，预测下一个词的分布



乱序GPT：以任意次序计算条件概率



- 序列长度固定=28
- 物理量ID编码使用 onehot
- Features=[值, Mask, 1D-code]
- Transformer: 8层, 4头, d=128; 160万参数
- 用高斯混合模型 ($N_{\text{GMM}}=20$) **显式输出概率密度函数**


$$p(x) := \sum_{i=1}^{20} \frac{w_i}{\sqrt{2\pi} \sigma_i} e^{-\frac{(x-\mu_i)^2}{2\sigma_i^2}}$$

- 按 $0 < r < 1$ 的**随机比例**生成mask;
- 被mask的维度value也设为0, ID照常;
- Loss = -loglikelihood
- 理论收敛性:


给定条件下,预测分布在数据集上的

最大化likelihood, 等价于最小化预测分布与数据集的真实分布间的KL散度 (Goodfellow2016)

在所给定条件下的切片



MULTI-1D数据集制备流程




- 辐射温度波形抽象为 foot平台、二次函数形ramp、最大值平台 (无coast)
- 靶抽象为半径、CH厚度、DT厚度


	Tr	Tr _{foot}	R	Δ _{DT} /R	t _{ramp} /R	Δ _{CH} /R	t _{foot}
mean	290 eV	115 eV	800 μm	0.06	0.32	0.28	/
±range	15%	18%	50%	50%	60%	50%	/

- t_{foot}不是独立参数，每个设计都应当被调到最优 shock timing

- 对少量样本，扫描最优 t_{foot}；训练 t_{foot} 预测器
- 训练一个低精度代理模型；用来粗估 logY v_{imp} P_{HS} logG



- 生成大量6D随机采样
- 用低精度代理模型粗筛调整分布




- 用 t_{foot} 预测器补全设计维度

- 跑数值模拟
- 16k+1k 样本, 500核时
- (有/无 α 自加热*2)

- 后处理，计算输出量
($E_{\text{las}}: \int_0^{\text{BT}} \sigma T_r^4 dt \cdot \text{靶丸表面积} \cdot \text{系数}$)
- 训练/测试集: 16k/1k

模型可以有效拟合数据的分布

边缘分布 (输入全为mask时, 各维度的输出)




黑线为数据集的真实边缘分布

红线为GMM给出的概率密度

代理模型模式 (前6维可见, 其余mask)


设计维度可见, 模型直接“抄答案”, 输出 δ 分布



条件前6维, 其余维度也自动“塌缩”到 δ 分布


模型可以有效扮演正向与逆向代理模型：在测试集上的表现

正向代理模型：预测平均 $R^2=0.9950$ ；RMSE=0.0161




横轴：测试集数据（已归一化）；纵轴：预测分布($\sim \delta$ 分布)的峰位置

逆向代理模型：预测的平均 $R^2=0.9996$ ；RMSE=0.0084



由于模型被训练去拟合**任意条件概率**

- “前向”与“逆向”在训练时是完全一样的
- 前向模型的可靠性就意味着逆向模型的可靠性
- **cycle consistency** 在统计意义下自动满足
- 二者的(测试)RMSE随loss同步下降



模型可以给出任意条件下、任意变量的后验分布预测

- 条件 $Tr=300\text{eV}$, $Y_{\text{with-}\alpha}/Y_{\text{no-}\alpha}=5$ (热斑自加热临界):


给定 x_0 , 先预测 $p(x_1|x_0)$ 在每个 x_1 处的值

再对每个 x_1 计算 $p(x_2|x_0, x_1)$

二维分布 $p(x_1, x_2|x_0)$ 即为此二者乘积

对称性:



$$p(x_1|x_0) p(x_2|x_0, x_1) = p(x_2|x_0) p(x_1|x_0, x_2)$$



- 如果条件很少: 预测分布 $\approx$ 数据集切片

- 但如果条件较多: e.g. NIF-like designs

$Tr=300\text{eV}$; $R=1.05\text{mm}$
 $\Delta_{DT}/R=6.2\%$; $\Delta_{CH}/R=25\%$



Gaffney et al, PoP 2024



- 训练集中只能切到8个点
 $(295 < Tr < 305)$
 $(1.0 < R < 1.1)$
 $(5.9\% < \Delta_{DT}/R < 6.5\%)$
 $(23\% < \Delta_{CH}/R < 27\%)$

- 从数据切片找规律, 总有切不到的时候;
- 但这里预测的后验分布总是归一化的

从预测的后验分布中, 可读出一些定标律

- 例如, 点火 (热斑自加热) 临界条件:

- 给定 $Tr=300\text{eV}$, $Y_{\text{with-}\alpha}/Y_{\text{no-}\alpha}=5$



Levedahl & Lindl: $E \propto \alpha^{1.7} v^{-5.5}$

Basko & Johner: $E \propto \alpha^3 v^{-9.1}$

Meyer-ter-Vehn: $E \propto \alpha^{1.9} v^{-5.9}$



HTL2001 LASNEX: $E \propto \alpha^{2.7} v^{-7.2}$

Lawson-type criterion

$$\rho RT \sim PR \sim \text{const.} \\ \Rightarrow E \sim PR^3 \sim P^{-2}$$

- 再例如, 阻滞压强定标律:

- 左: 给定 $Tr=260\text{eV}$, $R=0.5\text{mm}$, $\alpha_{DT}=2.8$





- 右: 给定 $Tr=260\text{eV}$, $R=0.5\text{mm}$, $v_{\text{imp}}=360\text{ km/s}$

$$\frac{P_{\text{stag}}}{P_{\text{if}}} \propto Mach^3 \Rightarrow P_{\text{stag}} \sim v_{\text{imp}}^3 \alpha_{DT}^{-0.9}$$

给定某些输出维度，其余维度的条件分布即为其贝叶斯后验


- 给定靶半径R;
- 假设“实验测量”到了 Bang Time 和 $\log Y$
- 直接生成其余变量的后验分布:

- 等价于用“专职代理模型”跑蒙卡:



按需求生成新设计：不等式约束下的自回归生成


	Tr (eV)	logY	E _{las} (MJ)	v _{imp}	CR _{DT}	BT(ns)	At
Lower	260	17.5	1.0	350	0.0	-Inf	-Inf
Upper	300	+Inf	2.5	410	18	12	0.0





再用代理模型模式做一遍筛选

重新做数值模拟：


96%的生成样本满足所有约束



生成的多样性：



讨论：数据量需求 -- 将数据集扩展至64k、缩减至4k、甚至1k



发现：随着数据量减少，预测的分布丢失了一些细节，**但宏观结构还是对的...**

毕竟，这里真正涉及的tradeoff并不算复杂；1k样本描述这些宏观结构可能还真差不多

小结：

- 构造了一个新的AI模型框架：自回归+GMM直接建模高维联合概率密度
- 提供了一种研究ICF问题变量之间全局关联的新视角
- 展示了用统一的预训练模型可以回答诸多不同场景的ICF问题